

目录

1	问题分析	3
1.1	问题简介	3
1.2	数据分析	3
1.3	数据特点	4
1.4	难点分析	4
2	方法选择	4
2.1	端到端学习：CNN 方法	4
2.1.1	应对维度灾难	5
2.1.2	应对域偏移问题	5
2.1.3	应对复杂信号	5
2.2	手动特征工程：XGBoost 方法	5
2.2.1	应对维度灾难	6
2.2.2	应对域偏移问题	6
2.2.3	应对复杂信号	6
3	数据预处理	6
3.1	数据清洗	6
3.2	数据标准化	7
4	1D-CNN 方法	8
4.1	数据降维	8
4.2	模型架构	9
4.3	训练过程分析	10
4.4	模型置信度分布分析	11
4.5	混淆矩阵分析	12
4.6	综合评价	13
4.7	可能的改进方向	13
4.8	小结	13
5	XGBoost 方法	13
5.1	选取原因：频域特征重要性	13

5.2	手动特征工程	14
5.3	模型训练（分组交叉验证）	16
5.4	测试集处理与预测	18
5.5	XGBoost 方法总结	19
6	STFT 频谱图 +CNN 分类	19
6.1	方法思路	20
6.2	时间段分割	20
6.3	频域特征提取（STFT 频谱图）.	21
6.4	CNN 模型训练	22
6.5	验证与结果分析	23
6.6	测试集预测	25
6.7	STFT+CNN 方法总结.	26
7	项目总结与心得	26
7.1	项目总结	26
7.2	心得体会	26
7.4	参考文献	27

第1章 问题分析

1.1 问题简介

赛题链接:<https://www.kaggle.com/competitions/industrial-wear-prediction/overview>




图 1: Kaggle 竞赛页面

本项目属于工业预测性维护中的设备磨损分类问题。核心任务是基于设备运行时的声学信号，准确判断设备是否处于磨损状态。这是一个典型的监督学习中的时序数据二分类问题，具有明确的工业应用背景和实际价值。

我们的任务是：通过分析设备运行时产生的 38000 维声学信号，构建一个分类模型，其输出为二元标签——0 代表“正常”，1 代表“磨损”。

1.2 数据分析

1. **数据来源**：数据来源于工业设备运行时的声学传感器，采集的是设备在运行过程中产生的声音信号。

2. **输入 (X) 与输出 (Y)**：

- X：每个样本是一个 38,000 维的时序信号，代表了在固定时间窗口内采集到的声音振幅序列。
- Y：二分类标签，0（正常）或 1（磨损）。训练集中正负样本为 1:1。

3. 样本规模：

- 训练集：640 个样本，均匀来自 4 次独立运行 (Run 1-4)，每次运行 160 个样本。
- 测试集：360 个样本，其中 160 个来自前四次运行 (Run 1-4)，200 个来自第 5 次运行 (Run 5)。

1.3 数据特点

1. **数据质量：**通过缺失值、异常值分析，我们可以看到，数据完整性好，无显性缺失值。主要质量问题在于不同样本间的基线差异（如传感器灵敏度、环境背景噪声），这需要通过数据的标准化来解决。
2. **时域特点：**原始数据具有时序性。每个维度对应一个具体的时间点，有明确的物理意义（特定时刻的振幅），我们可以从数据的局部结构中寻找设备磨损信息。因此，不能进行传统的 PCA 降维。
3. **频域特点：**高维度的采样数据表明数据采样频率足够高，满足奈奎斯特采样定理的要求。因此实验数据能够捕获与机械磨损相关的中高频振动与声学特征，为频域分析提供了基础。同时，我们在进行数据降维时，不能进行极端降采样，否则会造成频域混叠，丢失一些判断磨损的信息。

1.4 难点分析

1. 仅 640 个训练样本，每个样本包含 38,000 个时序点，小样本高维度，可能造成维度灾难。
2. 训练数据来自 Run 1-4，而大量的测试数据来自 Run 5，不同运行批次间的数据分布存在差异，存在域偏移问题。
3. 声学信号复杂，包含丰富的频率成分和时间模式，需要有效捕捉与磨损相关的关键特征。

第 2 章 方法选择

我们选择 1DCNN 和 XGBoost 两种方法，来解决前面列举的维度灾难、域偏移、复杂性问题，原因如下。

2.1 端到端学习：CNN 方法

卷积神经网络 (CNN) 是一种深度学习模型，擅长处理图像和时序数据。它通过卷积层提取局部特征、池化层降低维度，并通过全连接层进行分类或回归。CNN 具有参

数共享和空间不变性，能够自动学习数据中的关键模式，提高特征表示能力，广泛应用于计算机视觉和信号处理领域。

2.1.1 应对维度灾难

1. 与传统机器学习的手工特征工程不同，CNN 通过其卷积核在原始输入数据上自动进行滑动扫描，可直接进行特征自动学习。它能够发现隐藏在高层维度中的细微模式，从而避免了在高维特征空间中盲目搜索的困境。
2. 同一个卷积核会在输入序列的每一个位置重复使用，这意味着无论输入序列有多长，对于同一种特征模式，模型只需要学习一次。这种参数共享机制极大地减少了模型需要训练的参数总量，从而降低了模型的复杂度，防止因参数过多而在高维空间中产生的过拟合问题。
3. 此外，池化层本身就是一种降维操作。它们通过下采样，在保留最显著特征信息的同时，压缩了数据的空间尺寸，减少了后续层需要处理的参数量。

2.1.2 应对域偏移问题

深度学习模型具有优秀的迁移学习能力。过程是：首先在一个大规模、通用的源域数据集上对 CNN 模型进行预训练，使其学习到基础且通用的特征表示。然后，将这个预训练好的模型作为起点，使用相对少量的目标域数据对整个网络或仅对最后几层进行微调。

然而在本题目中，run5 的数据全部位于测试集中，此方法无法实现，我们只能进行充分的特征工程，让 CNN 学习到核心的特征。

2.1.3 应对复杂信号

CNN 通过堆叠多个卷积层和池化层，构建了一个深度的、层次化的特征学习架构。浅层的卷积核通常负责捕捉简单、局部的基元特征（如信号中的某个尖峰或转折）；随后，更深层的网络则将这些底层特征组合成更加复杂和抽象的高级特征（如一个完整的周期性模式或事件）。这种由简至繁、由局部到整体的学习方式，非常符合高维数据的内在结构，使得模型能够以一种高效且有序的方式理解和利用高维信息，而不是粗暴地记忆所有数据。

2.2 手动特征工程：XGBoost 方法

XGBoost（极端梯度提升），是一种梯度提升树模型。它通过迭代地训练一系列树模型，每一棵新树都致力于纠正前一棵树的错误，从而形成一个强大且精准的预测模型。它处理结构化表格数据效率高、预测精度优越和防止过拟合能力强，通常需要在输入模型前手动进行特征工程，以提取有意义的特征。

2.2.1 应对维度灾难

1. XGBoost 内置特征选择机制。在构建每一棵决策树的过程中，XGBoost 需要为每个节点寻找最佳的分裂特征和分裂点。它通过计算“增益”来评估每个特征分裂所带来的损失函数减少量。那些无法提供显著增益的冗余特征或无关特征，在树的分裂过程中会被自动忽略。
2. XGBoost 提供了丰富且精细的正则化超参数，有利于控制模型复杂度、对抗高维过拟合。
3. 高维数据经常伴随着稀疏性，而 XGBoost 的算法内部对稀疏数据格式有专门优化，能够自动学习出处理缺失值或默认方向的最优策略，从而高效地处理此类数据，而无需额外的预处理步骤。

2.2.2 应对域偏移问题

1. 通过手动特征工程，寻找域不变特征。例如，在时序数据中，可以提取频谱特征、统计特征（均值、方差、峭度等）而非原始波形，因为这些高阶特征可能对域的变化不那么敏感。然后，使用这些精心设计的特征来训练 XGBoost 模型。
2. 集成不同域的数据进行训练。这样模型在最初就能学习到不同域之间的变化，从而具备更好的泛化能力，对一个全新的域也会表现出更强的适应性。

2.2.3 应对复杂信号

XGBoost 的自动特征选择与重要性排序。XGBoost 在构建每棵树时，会基于“增益”自动选择最重要的特征进行分裂。训练完成后，可以得到所有特征的全局重要性排序。从而看出在成百上千个特征中，哪些特征对判断故障贡献最大。

第3章 数据预处理

3.1 数据清洗

首先，对训练集进行了缺失值检查，结果显示数据集的缺失值总数为 0，数据质量较高。

接下来，使用四分位距（IQR 方法）对所有数值特征列进行异常值检测。

检测结果显示，数据集存在大规模的数值离群现象：在总共约 24.32 百万个数据点中，有超过 335 万个点（约 13.8%）被标记为超出 IQR 边界，并且 640 个样本（即全部样本）均含有至少一个异常值。然而，由于本数据集是用于工业磨损预测的时序信号，

这些被 IQR 方法标记的离群点，可能代表了关键的工况变化、信号峰值或系统故障前的瞬时剧烈波动。这些波动信息对于判断是否磨损是有用信息。

因此，我们决定不采用传统的异常值删除或替换处理，而是继续使用 Z-Score 标准化方法。标准化通过重新调整数据的均值和方差，能够保留这些高价值的极端信号的相对位置和信息，同时将其缩放到模型可接受的尺度上，从而避免了删除关键特征信息所导致的模型性能下降。

3.2 数据标准化

1. 逐样本标准化

每条时间序列单独计算均值和方差，并分别归一化。这虽然使每个样本的波形形态清晰，但忽略了不同样本之间的整体幅度差异，不利于模型捕捉”磨损刀具”和”新刀具”在声能量或信号幅度上的差异。

```
数据读取成功，形状为： (640, 38002)
数据标准化完成，展示前3行部分数据：
      2      3      4      ...      7      8      9
0  0.044791 -0.072035  0.031486  ...  0.077089 -0.003703 -0.079884
1 -0.016778  0.019941 -0.019242  ...  0.000300 -0.016030 -0.045928
2  0.002913 -0.041297  0.026812  ...  0.023868 -0.011240 -0.050882

[3 rows x 8 columns]
图像已保存为 'normalized_signals.png'

进程已结束，退出代码为 0
```

图 2: 逐样本标准化输出




图 3: 逐样本标准化数据

2. 改进策略：

原有的逐行（或逐样本）循环标准化方法效率低下，耗时较长。

为了优化性能，我决定将标准化策略改为使用 `sklearn.preprocessing.StandardScaler` 一次性拟合所有特征列（即跨所有样本）。在保存标准化后数据时，我遇到了 I/O 性能瓶颈，因此引入了 Dask 库，利用其并行处理能力和 `dask.dataframe` 模块来加速大文件的保存操作。为了监控 Dask 任务的执行状态，我使用了 `dask.diagnostics.ProgressBar`，这使得所有并行计算和 I/O 任务的进度都能以可视化进度条的形式实时显示在终端，极大地提高了对大数据操作的可控性。此外，在调试过程中，我发现代码运行在可视化步骤后出现卡顿。经过排查，确定是 `matplotlib.pyplot.show()` 函数在某些执行环境（如特定 IDE 或终端）下会阻塞主进程，直到用户手动关闭弹出的图形窗口，才会继续执行后续的文件保存和日志输出任务。解决了这一阻塞问题后，代码成功高效地完成了所有任务，包括生成和保存了近 500MB 的标准化数据文件。




图 4: 最终标准化的数据

标准化后的数据，可以直观地显示，磨损刀具（橙色）的信号波动更大，振幅明显偏高；崭新刀具（蓝色）的信号相对平稳，振幅变化较小。

第 4 章 1D-CNN 方法

4.1 数据降维

我们前后进行了三次不同的降维方法尝试，都没有得到相对准确的结果。

1. PCA（主成分分析）方法

主要基于数据的高维时序特性：一方面，数据特征数量众多（共 38002 个），容易导致维度灾难并影响模型泛化能力，PCA 能够通过少数主成分保留大部分原始信息；另

一方面，时序数据存在显著的多重共线性，而 PCA 可以消除特征间相关性，生成相互独立的主成分。

- (a) 数据准备：用全局 Z-Score 标准化后的数据，分离出 ID 列、标签列和特征列。
- (b) 确定最优主成分数量：通过计算所有可能主成分的累积方差解释率，选择能够覆盖 95% 方差的成分数量。
- (c) 可视化方差解释率并保存图像。
- (d) 使用选择的主成分数量重新进行 PCA 降维。

2. 下采样与形状重塑方法

为了让数据适应 1D CNN 模型的输入而进行的最后调整：

- (a) 下采样函数 (simple_downsample)：我实现了一个简单的等间隔采样函数。它沿着时序维度（特征维度）每隔 4 个点取一个点，将特征长度从 38000 均匀降采样到 9500 维。
- (b) 应用下采样：将此操作应用于已标准化的训练集和测试集数据。
- (c) 形状重塑：最后一步是将降采样后的 2D 数据重塑为 3D 张量，这是 TensorFlow/Keras 的 Conv1D 层所要求的输入格式。

3. 时域分段重叠方法

为了在保留时序结构的前提下进行降维、加速训练，我们尝试进行滑动窗口时域分段处理。

- (a) 用全局 Z-Score 标准化后的 38000 维完整时序数据，用重叠窗口切成 8000 长度的片段，这样既保留了时序结构，又把训练样本从 640 个扩增到了 6000 多个。
- (b) 为了防止过拟合。模型上也做了改进，第一个卷积层用了步长 4 来加速，还加了 L2 正则化和 0.5 的 Dropout 来防止过拟合。

总结：三种方法降维后的数据，在后续的交叉验证中都出现了严重的过拟合问题。尽管训练集的准确率达到 90% 左右，但验证集的准确率始终保持在 50% 左右，这体现了模型无法将所学特征泛化到 OOD 的 Run 数据上。

为了提高模型的泛化能力，我们最终使用 1DCNN 模型直接从原始时序数据中学习时域和频域的特征，即直接处理 38000 个原始采样点，而不是依赖于预先提取的静态特征，以克服域偏移问题。

4.2 模型架构

1. 结构简介

本次实验采用基于一维卷积神经网络（1D-CNN）的时序信号分类模型。网络由多层卷积层、残差块（Residual Block）、批归一化层（Batch Normalization）以及全局平均池化层（Global Average Pooling）组成，并在分类头中加入 Dropout 与 L2 正则化，以缓解过拟合。

2. 模型参数

表 1: 1D-CNN 模型参数配置

参数名称	值
优化器	Adam (learning rate = 1e-3)
损失函数	Binary Crossentropy
正则化方式	L2 ($\lambda = 1e-4$)
Dropout 比例	0.6
输入序列长度	38,000
Batch Size	20
最大迭代轮次	100 (提前停止于第 15 轮)

3. 核心组件：残差块

残差块包含两条路径：主路径和短路连接 (Shortcut)。

主路径: Conv1D→BatchNormalization→ReLU→Conv1D→BatchNormalization

短路连接: 当输入通道数与输出通道数不一致时，使用 1×1 卷积调整通道数，否则直接使用输入张量。

输出: 主路径输出与短路连接相加后，通过 ReLU 激活。

4.3 训练过程分析

模型训练采用单次 Run (Run 1)，训练与验证的损失及准确率曲线如图 4-1 所示。




图 5: 1D-CNN 训练过程曲线

从图 4-1 可以看到：

- 训练损失 (Train Loss) 在前几个 epoch 内快速下降，说明模型能够较快地捕捉主要特征；
- 验证损失 (Val Loss) 呈现明显波动，甚至多次反弹，表明模型出现了一定程度的过拟合；
- 训练准确率 (Train Accuracy) 稳定在 0.97–0.99 之间，而验证准确率 (Val Accuracy) 在早期较高 (0.96)，随后明显下降并出现波动。

由此推断，模型在 Run 1 中具有较强的拟合能力，但泛化性能仍需进一步提升。

4.4 模型置信度分布分析




图 6: 1D-CNN 模型预测置信度分布

如图 4-2 所示，模型预测置信度主要集中在 0 和 1 两端，说明 CNN 模型在多数样本上表现出较高的决策置信度，分类边界非常明确。但这种分布也表明模型可能存在“过度自信”的问题，尤其在样本较少或类别不平衡时，会影响概率校准的可靠性。

4.5 混淆矩阵分析




图 7: 1D-CNN 模型混淆矩阵

从图 4-3 可见，模型在验证集上的预测结果如下：

表 2: 1D-CNN 模型预测结果

实际\预测	预测为 0	预测为 1
实际为 0	61	4
实际为 1	0	63

计算得到各项指标如下：

表 3: 1D-CNN 模型性能指标

指标	数值
准确率 (Accuracy)	96.8%
假阳性率 (FPR)	6.15%
假阴性率 (FNR)	0%
精确率 (Precision)	94.0%
召回率 (Recall)	100%

模型在验证集上实现了较高的总体准确率，且未出现假阴性样本 ($FN=0$)，说明模型对正类的识别能力非常强。少量假阳性样本表明模型在负类判断上略有冗余，但误差总体可控。

4.6 综合评价

从整体来看：

- 模型在训练阶段表现优异，收敛迅速；
- 验证集准确率达到 96.8%，分类性能较高；
- 验证损失波动较大，说明模型对验证集的拟合不够稳定；
- 模型在置信度预测上较为“激进”，需要进一步校准。

4.7 可能的改进方向

1. 增加正则化力度：例如将 L2 系数调大或增大 Dropout 比例，以缓解过拟合。
2. 引入交叉验证 (K-Fold)：提高模型稳定性和泛化能力。
3. 使用学习率调度 (Learning Rate Scheduler)：在训练后期减小学习率，防止振荡。
4. 置信度校准 (Calibration)：可采用 Temperature Scaling 等方法改善预测置信度的可解释性。
5. 模型融合 (Ensemble)：与其他模型（如 XGBoost）结合，有望进一步提升整体性能。

4.8 小结

在本次实验中，基于 1D CNN 的信号分类模型在 Run 1 中达到了较高的准确率与可靠性。模型能够有效捕获时序信号特征，展现出良好的分类性能。尽管存在一定过拟合现象，但其在置信度稳定性与召回率方面的表现仍然优异，为后续模型优化提供了坚实基础。

第5章 XGBoost 方法

5.1 选取原因：频域特征重要性

在前面的 CNN 学习过程中，存在难以克服的过拟合的问题，这是因为我们的训练集样本数较少 (640 个)，而声学时间序列又很大，关键特征散落在其中，无法被学习到。

赛题指出，频域特征很有用，可能只有部分的频域特征是能够有效反映出磨损信息的。因此，我们决定寻找一种能够提取数据频域特征的方法。

综合特征提取难度、模型训练难度、模型的分类问题解决能力，我们选择了轻量级的手动特征工程 + XGBoost 模型，对我们的想法进行初步验证。该模型的优势在第二部分已经叙述过，就不赘述。




图 8: 赛题页面截图

5.2 手动特征工程

这一步中，我们通过手动选取物理特征，将原始高维时间序列数据转换为适合 XGBoost 模型的低维特征向量，提取的特征如下：

- 时域统计特征：**从振幅分布角度描述信号，包括基础统计量（均值、标准差）、高阶统计量（偏度、峰度）和分位数，用于捕捉信号的总体能量、波动性、冲击事件和分布形态。
- 分段统计特征：**将序列分割为 5 段，分别计算统计量。旨在捕捉信号在时间轴上的异质性，发现可能被全局统计所掩盖的局部异常磨损模式。
- 频域特征：**这是声学分析的核心。通过傅里叶变换提取频谱统计、主频位置。创新性地计算了中频带和高频带的能量占比，这基于机械故障诊断的先验知识，且对设备转速变化不敏感，极大地增强了模型应对域偏移的鲁棒性。

频域特征说明：

- 平均频谱能量： $\text{mean}(\text{fft_vals})$ 反映信号在频域中的平均能量强度
- 频谱能量标准差： $\text{std}(\text{fft_vals})$ 衡量频谱能量的离散程度，表征频率成分的分布均匀性
- 主频能量： $\text{max}(\text{fft_vals})$ 识别频谱中的最强频率成分的能量值
- 主频位置： $\text{argmax}(\text{fft_vals})$ 定位主频在频谱中的索引位置，反映主导振动频率

- 中频能量占比: $\text{sum}(\text{fft_vals}[1000:3000]) / (\text{sum}(\text{fft_vals}) + 1\text{e-}8)$ 计算 1000-3000Hz 频段能量占总能量的比例, 捕捉关键工作频段特征
- 高频噪声占比: $\text{sum}(\text{fft_vals}[3000:]) / (\text{sum}(\text{fft_vals}) + 1\text{e-}8)$ 计算 3000Hz 以上高频噪声能量占比, 反映信号纯净度

4. **Hjorth 参数:** 借鉴自生物信号处理, 描述信号的动态特性 (活动性、移动性、复杂性), 为模型提供补充信息。

接下来, 构建特征矩阵, 最终特征数为 30, 并添加 ID 和 label 列后保存。

绘制 30 个特征直方图:




图 9: 特征直方图分布

绘制特征相关性热力图:




图 10: 特征相关性热力图

可以看出，除对角线（特征与自己的关系为 1 以外，特征与其他特征之间的相关性绝大部分在 0.5 以下，一结果表明，特征之间的共线性较弱，我们成功提取了一组相互独立、信息重叠度低的特征，为模型构建奠定了良好基础。

5.3 模型训练（分组交叉验证）

1. 特征级标准化

对特征做标准化以助于 XGBoost 收敛更快更稳定，但此处仅基于训练集拟合，避免测试集信息泄露。

2. XGBoost 模型配置

XGBoost 参数配置

```
XGBClassifier(  
    n_estimators=200,    # 树的数量  
    max_depth=6,        # 树的最大深度  
    learning_rate=0.1,   # 学习率  
    subsample=0.8,      # 样本采样率  
    colsample_bytree=0.8, # 特征采样率  
    random_state=42,     # 随机种子  
    n_jobs=-1            # 使用所有CPU核心  
)
```

3. 模型训练（进行 Run-wise 分组交叉验证）

假设数据按 4 个实验运行顺序排列（每个 run 包含 160 个样本，80 正例 + 80 负例），使用 GroupKFold 进行 4 折交叉验证，确保同一 run 的数据不会同时出现在训练集和验证集中，有效防止了 run 间的信息泄露。

在这一框架下，XGBoost 模型通过设定好的参数进行训练，每折都独立评估模型在未见 run 上的准确率，最终计算平均交叉验证准确率，作为模型泛化能力的可靠指标。




图 11: XGBoost 训练/验证准确率曲线

输出如下:

加载预处理数据...

数据形状: (640, 32)

特征矩阵形状: (640, 30)

标签分布: {1: 320, 0: 320}

进行特征级标准化...

标准化后特征范围: [-5.463, 7.588]

构建run标签: 640 个样本, 4 个run

开始训练XGBoost模型...

Fold 1: Accuracy = 0.9812

Fold 2: Accuracy = 0.9875

Fold 3: Accuracy = 0.9750

Fold 4: Accuracy = 1.0000

平均CV准确率: 0.9859 (+/- 0.0185)

根据运行结果, 平均交叉验证准确率为 0.9859, 这说明模型在训练集上已经有了比较好的分类性能。

4. 特征重要性分析

输出前 10 个最重要特征, 并用水平条形图展示前 15 个特征的重要性排序, 从而识别对刀具状态分类最关键的特征, 用于后续解释或降维。

输出特征重要性排序如下:

Top 10 重要特征：

	feature	importance
21	feat_21	0.215445
22	feat_22	0.181004
28	feat_28	0.123701
16	feat_16	0.068979
1	feat_1	0.058733
10	feat_10	0.054603
9	feat_9	0.044706
14	feat_14	0.037773
29	feat_29	0.025845
3	feat_3	0.023356




图 12: XGBoost 特征重要性排序

这里排序靠前的 21、22、28 等特征很可能就是反映设备磨损的关键频域特征。

5. 保存最终模型和预处理器

保存最终模型和预处理器供后续在测试集上使用。

5.4 测试集处理与预测

1. 测试集预处理

使用训练集拟合的 StandardScaler 加载模型和标准化器，对测试集执行与训练集完全相同的预处理流程，包括逐样本标准化、特征提取及标准化。

2. 测试集结果预测

对测试集预测输出类别及预测概率，生成提交文件及带置信度的预测文件，结果显示总样本数、正负类数量及其占比。

预测结果如下：

=== 预测结果统计 ===

总样本数：360

正类（1）数量：199

负类（0）数量：161

正类占比：0.553




图 13: XGBoost 预测置信度分布

5.5 XGBoost 方法总结

从训练结果可以看出，XGBoost 方法在训练集的交叉验证中达到了 0.9859 的准确率，并且每个 fold 准确率都在 0.97 以上，预测结果置信度也达到了整体 0.9 以上，只有 8 个样本预测置信度低于 0.7，这些样本可能来自 OOD 数据（Run 5），需要做更深入的特征提取，并增强模型的泛化能力，来优化 Run5 预测的表现。这次初步的成功也证明了特征工程的重要性。

第6章 STFT 频谱图 +CNN 分类

在验证频域特征重要性后，我们希望回到 CNN 方法，进行特征工程 +CNN 的探索。

仅靠时域的数据无法使 CNN 模型学习到磨损与关键频域特征之间的联系，因此我们结合信号分析与处理的知识，针对性地查找并阅读了论文《Data-driven tool wear prediction in milling, based on a process-integrated single-sensor approach》中的方法，并参考其中的“频域特征提取 + CNN 分类”进行了迁移应用。

6.1 方法思路

STFT 频谱图 + CNN 分类

采用关键预处理方法——短时傅里叶变换 (STFT)，将一维时间序列数据转化为二维的频谱图 (Spectrogram)

表 4: STFT+CNN 方法流程

阶段	目标	采用方法	方法优势
时间段分割	去除静止噪声段、提取有效加工段，避免噪声干扰	峰峰值检测 + 阈值分割	提高特征提取效率
特征提取 (频域)	表征磨损相关频带特征，频率特征显著	短时傅里叶变换 (STFT)	同时保留时间和频率信息
模型训练	建立分类器区分正常/磨损	小型 CNN (输入: STFT 图)	自动提取局部频谱模式 (如主频能量分布、磨损纹理)
验证与泛化	跨运行验证	Leave-One-Run-Out 验证 (LOOR)	评估模型的分布泛化能力

6.2 时间段分割

1. **目的:** 利用滑动窗口峰峰值方法来找出设备真正加工的时间段

2. **原理**

(a) 滑动窗口峰峰值

$$\ddot{x}_{p2p}(t) = \max(\ddot{x}_{t-w+1}, \dots, \ddot{x}_t) - \min(\ddot{x}_{t-w+1}, \dots, \ddot{x}_t)$$

其中 w 为滑动窗口长度。

(b) 低位均值

$$m_{p2p} = \frac{1}{N} \sum_{i=\alpha_0 N}^{\alpha_1 N} \dot{x}_{p2p}^\uparrow[i]$$

对峰峰值排序后取低百分位均值， $\alpha_0 = 0.01$ ， $\alpha_1 = 0.03$

(c) 阈值

$$th = \alpha_2 \cdot m_{p2p}, \quad \alpha_2 = 10$$

当 $\ddot{x}_{p2p}(t) > th$ 时，认为该时间段为加工段。

3. 可视化结果




图 14: 时间段分割结果

上半部分是原始信号；下半部分为峰峰值与阈值线，浅蓝色区域表示”加工有效段”。图像含义：能直观看到设备在何时真正开始切削，说明预处理有效地剔除了空转噪声。

6.3 频域特征提取 (STFT 频谱图)

1. STFT 定义：

$$S(f, t) = \sum_{m=0}^{M-1} x_t[m] e^{-2\pi j f m / M}$$

其中 $S(f, t)$ 为时间-频率能量谱，通过计算 $\log(1 + |S|)$ 压缩动态范围。

2. 提取结果 (任选一组数据进行绘制)




图 15: STFT 频谱图示例

横轴为时间，纵轴为频率，颜色表示声能强度。

3. 结果分析

磨损刀具通常在中高频区 (3-8 kHz) 能量增强；正常刀具在低频区域能量集中。STFT 图能反映这种能量分布变化。

可以看到：

- (a) 正常刀具的频谱能量主要集中在低频 (<3 kHz) 区域；
- (b) 磨损刀具的中高频 (3-7 kHz) 能量明显增强，且能量分布更为分散；
- (c) 这种能量转移与刀具磨损过程中摩擦和冲击噪声增加相对应。该特征差异正是卷积神经网络 (CNN) 在 STFT 图像中训练与判别的关键信息。

6.4 CNN 模型训练

1. 模型架构

采用小型 3 层 CNN (1→16→32→64 通道) 模型，对 STFT 图像分类。

CNN 的核心公式：

$$y_{ij}^{(l)} = \sigma \left(\sum_m \sum_n w_{mn}^{(l)} x_{i+m, j+n}^{(l-1)} + b^{(l)} \right)$$

其中：

w_{mn} 为卷积核；

σ 为激活函数 (ReLU)；

$y_{ij}^{(l)}$ 为特征图输出。

2. 训练损失函数 (交叉熵):

$$\mathcal{L} = -\sum_i [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

6.5 验证与结果分析

采用 **Leave-One-Run-Out** 验证:

每次留一个 Run 做验证, 其余三个 Run 训练。

表 5: STFT+CNN 模型验证结果

Run	Val Acc
1	0.96875
2	0.9875
3	0.98125
4	0.9875




图 16: 交叉验证准确率

该图展示了四个 Run 分别作为验证集时的交叉验证准确率。模型在四个运行下均能达到 96%–99% 的精度, 泛化性极强。




图 17: STFT+CNN 验证准确率曲线

显示每个 Run 的验证准确率随 epoch 增长的曲线。可见模型在约 3–5 个 epoch 即收敛，训练稳定。




图 18: STFT+CNN 混淆矩阵

该图为标准化混淆矩阵，清晰地展示了 CNN 分类模型在区分“正常”与“磨损”状态上的卓越性能。具体而言，模型对“正常”类别展现了完美的识别能力，其召回率高达 100%，所有真实状态为正常的样本均被正确分类，无一误判为磨损。

对于“磨损”类别，模型同样表现出高度可靠性，召回率达到 96%。这表明模型能精准捕捉绝大多数磨损状态。仅存的误分类表现为 3.7% 的磨损样本被错误地判定为“正常”，此类错误在工业预测性维护领域可被定义为“漏报”。

综合来看，模型在两个类别上的平均分类准确率超过 98%，不仅证明了其具备可靠区分两种状态的核心能力，也表明其泛化性能良好，未出现明显的类别偏差。唯一的优化方向在于进一步降低那 3.7% 的漏报率，这对于某些对故障“零容忍”的高风险应用场景至关重要。总体而言，该 CNN 模型已具备投入实际应用的高置信度。

6.6 测试集预测

程序最后在所有训练数据上重新训练 CNN，并对 test.csv 预测，生成 submission.csv。

6.7 STFT+CNN 方法总结

这个方法基于声学信号构建了一套完整的分析流程：

首先通过滑动峰峰值阈值法定位有效加工段（公式 1-3）；进而利用短时傅里叶变换（公式 4）将其转换为时间-频率分布；核心模型采用轻量级卷积神经网络（CNN），直接对 STFT 时频图进行分类识别，并通过留一运行交叉验证（LOOR）评估其泛化性能。

实验结果表明，该模型在四个运行数据上的平均验证准确率可达约 98%，能够稳定区分刀具的正常与磨损状态。可视化分析进一步揭示，磨损刀具在中高频区域能量显著增强，且谱熵增大。这不仅验证了“频域能量结构是主要判别依据”的论断，也证明了声学特征与刀具磨损物理状态的高度一致性，其效果优于单纯的统计或时域模型。

第 7 章 项目总结与心得

7.1 项目总结

本项目针对工业设备磨损预测问题，系统地探索了多种机器学习方法的应用效果。通过对 38000 维声学时序信号的分析，我们分别采用了 1D-CNN、XGBoost 和 STFT+CNN 三种不同的技术路线，并对各方法的性能进行了详细比较。

实验结果表明：

- **1D-CNN 方法：**在直接处理原始时序信号时表现出较强的特征学习能力，但在小样本情况下容易过拟合，验证集准确率达到 96.8%。
- **XGBoost 方法：**通过精心设计的特征工程，特别是频域特征的提取，在交叉验证中达到了 98.59% 的准确率，证明了频域特征在磨损识别中的重要性。
- **STFT+CNN 方法：**结合了信号处理技术和深度学习优势，通过 STFT 将时序信号转换为时频图，再利用 CNN 进行分类，在四个运行数据上的平均验证准确率超过 98%，展现了最佳的泛化性能。

综合分析，基于频域特征的方法在设备磨损分类任务中表现最为优异，这为工业预测性维护提供了可靠的技术方案。

7.2 心得体会

通过本次项目，我们深刻体会到：

1. **特征工程的重要性：**在工业数据分析中，基于领域知识的特征工程往往比复杂的模型结构更为关键。特别是频域特征的引入，显著提升了模型的分类性能。

2. **多方法比较的必要性：**不同方法各有优劣，1D-CNN 适合端到端学习，XGBoost 对特征工程要求高但解释性强，STFT+CNN 结合了信号处理和深度学习的优势。
3. **域偏移问题的挑战：**训练数据与测试数据来自不同运行批次，存在明显的域偏移问题，这是工业场景中的常见挑战，需要采用针对性的技术手段。
4. **工程实践的价值：**从数据预处理、特征工程到模型训练和评估，完整的工程流程让我们对工业数据分析有了更全面的认识。

7.4 参考文献

1. Hirsch E, Friedrich C. Data-driven tool wear prediction in milling, based on a process-integrated single-sensor approach[J]. arXiv preprint arXiv:2412.19950, 2024.
2. Peng Y, Song Q, Wang R, et al. Intelligent recognition of tool wear in milling based on a single sensor signal[J]. The International Journal of Advanced Manufacturing Technology, 2023, 124(3): 1077-1093.
3. Yu W, Huang H, Guo R, et al. Tool Wear Prediction Based on Attention Long Short-term Memory Network with Small Samples[J]. Sensors & Materials, 2023, 35.
4. Kotha Amarnath S, Inturi V, Rajasekharan S G, et al. Combining Sensor Fusion and a Machine Learning Framework for Accurate Tool Wear Prediction During Machining[J]. Machines, 2025, 13(2): 132.